Relatório — Ataque de Evasão em Classificador de Imagens (FGSM e PGD)

Aula 10 · IA para Cibersegurança · Allan Accioly e Lucas Freitas · 09/11/2026

1. Modelo e acurácia (baseline)

Classificador binário (Cachorro × Gato) treinado no Teachable Machine (Aula 2), com entrada 224×224 normalizada em [-1, 1]. O ataque é de caixa-branca (usa o gradiente do modelo) e não direcionado.

- Acurácia sem ataque no conjunto de teste (15 imagens): **80%** (12 acertos).
- Imagem usada nos exemplos: pasta test/cat; o modelo previu **Cachorro** com confiança 0,938 (Gato: 0,062).

Atenção: a imagem é de um gato, então a previsão original já era um erro do modelo. O notebook usou a classe prevista como "classe verdadeira" nessa demonstração; por isso, nos exemplos abaixo o ataque levou o modelo a "Gato", que na verdade é a classe correta. As métricas de perturbação seguem válidas para medir quão pouco a decisão do modelo precisa ser alterada, mas a curva de acurácia (seção 4) usa os rótulos reais das pastas de teste.

2. Ataques aplicados e parâmetros

	FGSM	PGD
Ideia	1 passo: $x' = x + \varepsilon \cdot \text{sinal}(\nabla_x \text{perda})$	Vários passos de tamanho α, projetando a imagem na caixa de raio ε a cada passo
ε	Crítico = 0,005 (menor ε da grade que virou a previsão); também 0,03 para comparação justa	0,03 (imagem única); curva com ε de 0 a 0,15
Passos	1	20 (imagem única); 10 (curva)
α	—	0,005
Perda	Entropia cruzada	Entropia cruzada

As imagens são mantidas no intervalo válido [-1, 1] após cada perturbação.

3. Exemplos adversariais (antes e depois)

FGSM, ε = 0,005: Cachorro (0,94) → Gato (1,00). A imagem adversarial é quase idêntica à original; só se notam pequenos ruídos em regiões de textura. A perturbação amplificada (painel da direita) mostra um “chuvisco” espalhado por toda a imagem.



PGD, ε = 0,03, 20 passos: Cachorro (0,94) → Gato (1,00).



4. Métricas: imperceptibilidade, efetividade e custo

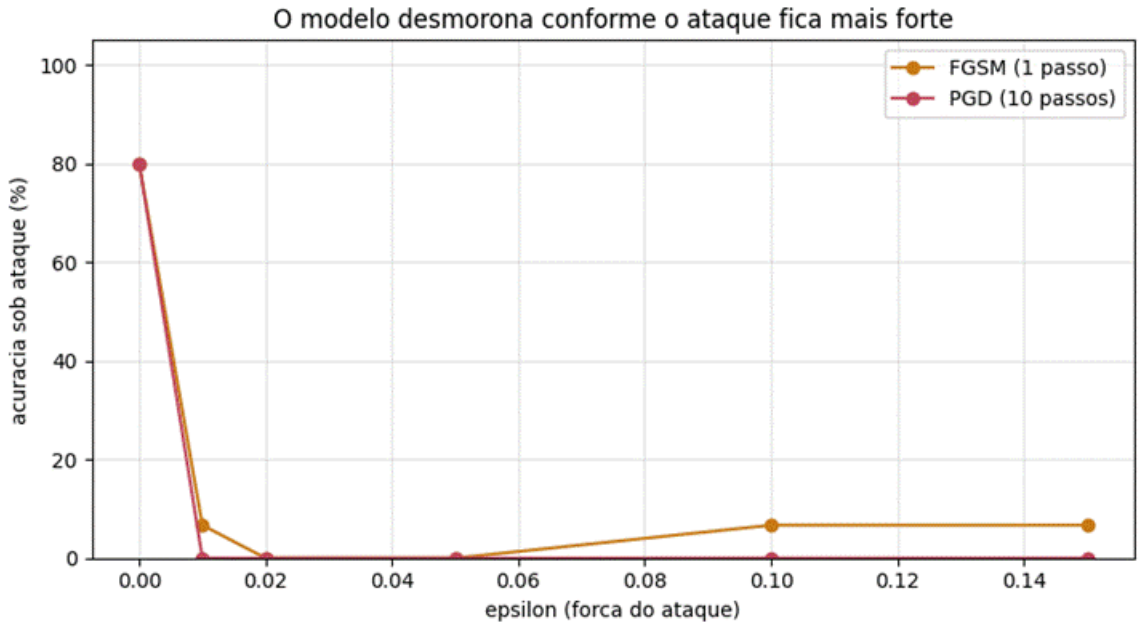
Ataque	L∞	L2	L0 (pixels alterados)	Confiança (antes → depois)	Virou?	Custo
FGSM, ε crítico 0,005	0,005	1,94	100%	0,938 → 1,000	Sim	1 passo
FGSM, ε 0,03	0,03	11,62	100%	0,938 → 1,000	Sim	1 passo
PGD, ε 0,03	0,03	7,38	84%	0,938 → 1,000	Sim	20 passos

- **Imperceptibilidade:** com o mesmo ε = 0,03, o PGD gerou perturbação menor (L2 = 7,38 contra 11,62) e alterou menos pixels (84%). A menor perturbação de todas foi a do FGSM em ε = 0,005 (L2 = 1,94); o PGD não foi testado nesse ε.
- **Efetividade:** os três ataques viraram a previsão, e o modelo passou a ter confiança ≈ 1,00 na nova classe.
- **Custo:** o FGSM usa 1 cálculo de gradiente; o PGD usa 20, cerca de 20 vezes mais caro.

Acurácia sob ataque (15 imagens de teste, rótulos reais):

ε	0	0,01	0,02	0,05	0,10	0,15
FGSM	80%	7%	0%	0%	7%	7%
PGD (10 passos)	80%	0%	0%	0%	0%	0%

Os dois ataques provocam queda de 80 pontos percentuais. O PGD zera a acurácia já em ε = 0,01, enquanto o FGSM ainda deixa 7% (1 imagem). O FGSM volta a 7% em ε altos, comportamento não monotônico possivelmente causado por um passo único grande demais.



5. Discussão: o que isso revela sobre a robustez do modelo

- **O modelo é muito frágil.** Um ε de 0,01 (cerca de 0,5% da faixa [-1, 1]) derruba a acurácia de 80% para no máximo 7%, com mudanças quase invisíveis.
- **A confiança não indica confiabilidade.** Depois do ataque o modelo erra com confiança ≈ 1,00.
- **Avaliar só com FGSM subestima o risco.** O PGD é mais efetivo e deve ser usado pelo defensor como referência de pior caso.
- **Impacto real:** sistemas de visão em câmeras, vigilância e veículos autônomos poderiam ser enganados por perturbações imperceptíveis.
- **Caminhos de defesa:** treinamento adversarial (tema da próxima aula), testes com vários ataques e pré-processamento das imagens.

Limitações: conjunto de teste de apenas 15 imagens (cada imagem vale ≈ 6,7 p.p.); métricas por imagem medidas em um único exemplo, que já era erro de baseline; desafio de ataque direcionado não concluído (a classe-alvo escolhida foi a própria classe original).